Atividade da Aula 1 – Análise da série temporal PETR4

César Willian Pacheco

Especialização em Inteligência Artificial & Ciência de Dados – PUCPR

Prof. Vinícius Mourão Alves de Souza

Setembro de 2026

Enunciado e dados

Analise a série temporal da Petrobras (`PETR4.csv`) disponibilizada: (i) a série é univariada ou multivariada? (ii) qual a taxa de amostragem? (iii) qual a dimensionalidade em termos de variáveis e quantidade de observações? (iv) em qual data a série apresentou o maior valor de fechamento (*Close*) e qual foi esse valor? (v) em relação às séries *Close* e *Volume*, o que se pode afirmar sobre tendência, ciclo, sazonalidade, autocorrelação e estacionariedade?

O arquivo do professor (`gdown 1vUh6gxcfFeKreamBk3JKS7QsAmRS8ME5`) contém cotações diárias de PETR4.SA no formato do Yahoo Finance, de 02/01/2020 a 30/12/2025. Como o CSV não estava na pasta local, a série foi reconstruída a partir da mesma fonte (API do Yahoo Finance, mesmo ticker e período); os valores de abertura, fechamento e volume conferem com os do arquivo do professor nas linhas verificadas (o arquivo do Yahoo traz 1494 pregões; o CSV do professor, 1493 – falta o pregão de 06/01/2020). Todos os números abaixo foram produzidos pelo script `analise_petr4.py` (pandas, statsmodels, scipy), anexo.

1 Univariada ou multivariada?

Resposta

Multivariada. Em cada instante (pregão) são registradas simultaneamente cinco variáveis: `Open`, `High`, `Low`, `Close` e `Volume` – exatamente o exemplo "Ações (open, close, low, high, volume)" dos slides. A quantidade de variáveis observadas ao mesmo tempo é o que define o caráter multivariado, e não o número de observações. A atividade, porém, pede a análise de *Close* e *Volume* **separadamente**: é a estratégia mencionada em aula de tratar cada canal como uma série **univariada** independente, o que permite aplicar as técnicas univariadas (média móvel, decomposição, ACF, testes de estacionariedade) ao custo de ignorar a relação entre os canais (por exemplo, o volume tende a disparar nos dias de queda brusca do preço).

2 Taxa de amostragem

Resposta

Uma observação por dia útil de pregão da B3 (frequência diária, intervalo *regular no calendário de negociação*, mas irregular no calendário civil). Entre observações consecutivas o intervalo é de 1 dia em 1153 casos, 3 dias em 286 (fins de semana), e de 2, 4 ou 5 dias em 54 casos (feriados). Não há observações em sábados ou domingos e há 70 dias úteis sem pregão (feriados da bolsa). Na média, são **249,3 observações por ano** (248 a 251 por ano civil), o que justifica usar $m \approx 252$ como período anual nas análises sazonais. A hora "16:56:00" presente nas datas do CSV é apenas o horário de captura da cotação de fechamento e não indica amostragem intradiária.

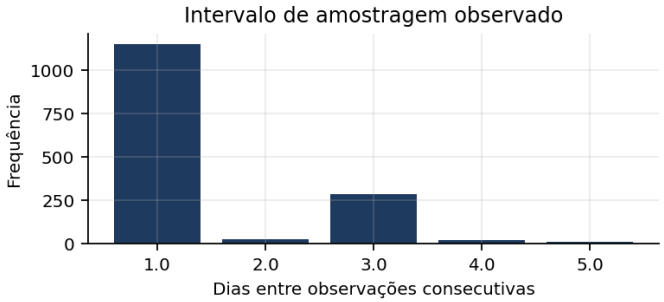


Figura 1: Distribuição dos intervalos (em dias corridos) entre observações consecutivas.

3 Dimensionalidade

Resposta

5 variáveis $\times$ **1494 observações** (matriz 1494×5), cobrindo 02/01/2020 a 30/12/2025 (seis anos civis). No arquivo original do professor há 1493 linhas, pela ausência de um pregão. Considerando somente as séries analisadas, cada uma (*Close* e *Volume*) é um vetor de comprimento $n = 1494$.

4 Maior valor de fechamento

Resposta

O maior fechamento ocorreu em **19/02/2024**, com **Close = R$ 42,90**. Para referência, o menor fechamento foi R$ 11,29 em 18/03/2020, no auge da queda provocada pela pandemia e pela guerra de preços do petróleo.

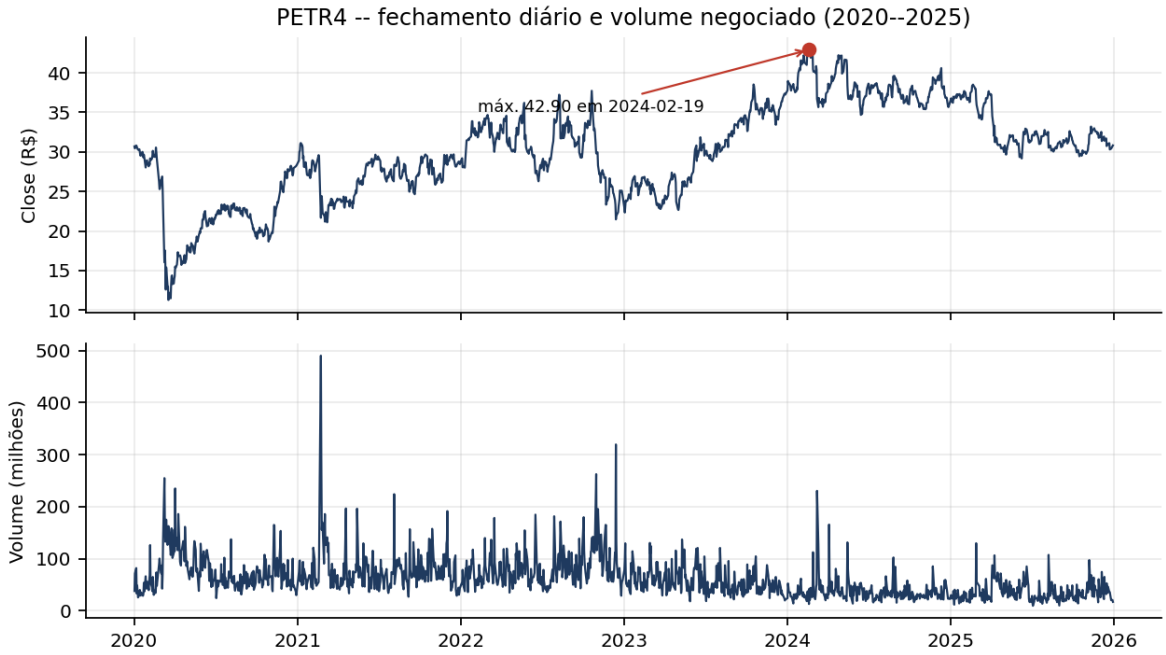


Figura 2: Fechamento diário e volume negociado de PETR4 (2020–2025); o ponto marca o maior fechamento.

5 Características das séries *Close* e *Volume*

Resumo quantitativo

Característica	Close (R$)	Volume (ações/dia)
Médias anuais	22,3 (2020); 26,9 (2021); 30,7 (2022); 29,7 (2023); 38,2 (2024); 32,7 (2025)	75,3 M (2020); 79,1 M (2021); 82,3 M (2022); 57,2 M (2023); 37,1 M (2024); 35,1 M (2025)
Variação início→fim	+0,4% (30,70 → 30,82)	−55% (37,8 M → 16,9 M)
Picos da série suavizada (ciclos)	set/2022 e mar/2024 (375 pregões entre eles)	abr/2020, abr/2021, out/2021, nov/2022 (234, 139 e 256 pregões)
Amplitude do componente sazonal anual	4,64 (15% da média); força sazonal 0,19	$1{,}2 \times 10^8$; força sazonal 0,25
ACF lag 1 / 5 / 21 / 252	0,993 / 0,963 / 0,849 / 0,165	0,639 / 0,426 / 0,271 / 0,159
ACF da 1ª diferença (lag 1)	0,000	−0,312
ADF (H_0: raiz unitária), p	0,153 (não rejeita)	$1{,}0 \times 10^{-5}$ (rejeita)
KPSS (H_0: estacionária), p	0,01 (rejeita)	0,01 (rejeita)
Média/desvio em 5 janelas	23,0/4,7; 28,7/3,1; 28,1/3,5; 37,1/2,7; 33,6/3,0	79,6/46,6; 74,5/29,4; 74,9/36,3; 41,4/22,5; 34,9/17,2 (milhões)

Limite de significância aproximado da ACF: $\pm 1{,}96/\sqrt{1494} = \pm 0{,}051$.

Tendência

Resposta

Close: não há uma direção única de longo prazo. A média móvel de 126 pregões mostra uma *tendência não monotônica*: queda abrupta no 1º trimestre de 2020, recuperação e alta até 2022, recuo em 2022–início de 2023, forte alta até o pico de 2024 e queda em 2025. Como a série termina praticamente no mesmo nível em que começou (+0,4%), a regressão linear global tem inclinação quase nula (≈ 0,01 R$/pregão); a tendência é *local*, como no exemplo da taxa de desemprego visto em aula.

Volume: tendência de longo prazo **decrescente**: as médias anuais caem de ≈ 80 milhões de ações/dia em 2020–2022 para ≈ 35 milhões em 2024–2025 (−55% ponta a ponta), com o volume mais alto concentrado nos períodos de crise (março de 2020) e de forte volatilidade.

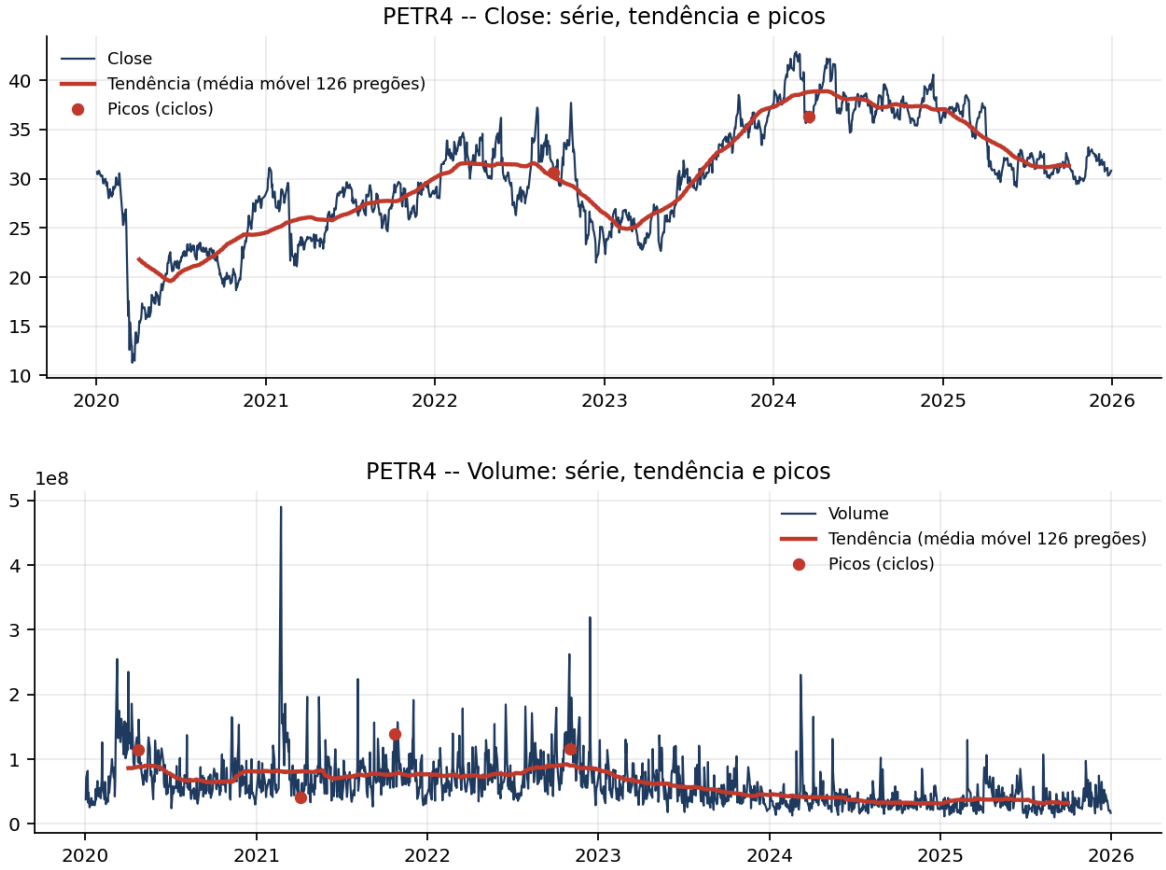


Figura 3: Séries com a tendência (média móvel centrada de 126 pregões) e os picos relevantes da versão suavizada.

Ciclos

Resposta

Ambas apresentam **oscilações de longo prazo com duração irregular** – o que os slides definem como ciclo, distinto de sazonalidade. Aplicando ao *Close* suavizado (média móvel de 63 pregões) a detecção de picos por proeminência, como no notebook do professor, obtêm-se picos em set/2022 e mar/2024, separados por 375 pregões ($\approx$ 1,5 ano); visualmente há ainda os vales de mar/2020 e mar/2023. Esses ciclos correspondem a ciclos econômicos e do preço do petróleo (pandemia, recuperação, guerra na Ucrânia, política de dividendos e preços da empresa) e não a um calendário fixo. No *Volume* os picos (abr/2020, abr/2021, out/2021, nov/2022) estão a 234, 139 e 256 pregões uns dos outros, também sem período constante: são episódios de estresse do mercado, não ciclos regulares.

Sazonalidade

Resposta

Não há sazonalidade relevante em nenhuma das duas séries. Na decomposição aditiva com período anual ($m = 252$), o componente sazonal do *Close* tem amplitude de 4,6 (15% da média) mas força sazonal de apenas 0,19: o componente que o método extrai é irregular, com amplitude menor do que a do resíduo (desvio 2,15), e não se repete de forma reconhecível ano a ano – é o mesmo "falso positivo" do contraexemplo da temperatura horária discutido em aula: `seasonal_decompose` sempre devolve algum padrão, cabe ao analista julgar se ele é real. A ACF no lag anual (252) é baixa (0,16 para *Close*, 0,16 para *Volume*) e não apresenta o pico que caracteriza séries sazonais como a temperatura (0,79 no lag 365) ou a demanda por bicicletas (picos em 24 e 168 horas). Também não há efeito de dia da semana: as médias de *Close* por dia da semana variam entre 30,02 e 30,17, e as de *Volume* sobem suavemente de segunda (58 M) a sexta (66 M) – um efeito de calendário fraco, que não configura um padrão sazonal definido. Isso é esperado em preços de ações: um padrão sazonal previsível seria rapidamente arbitrado pelo mercado.

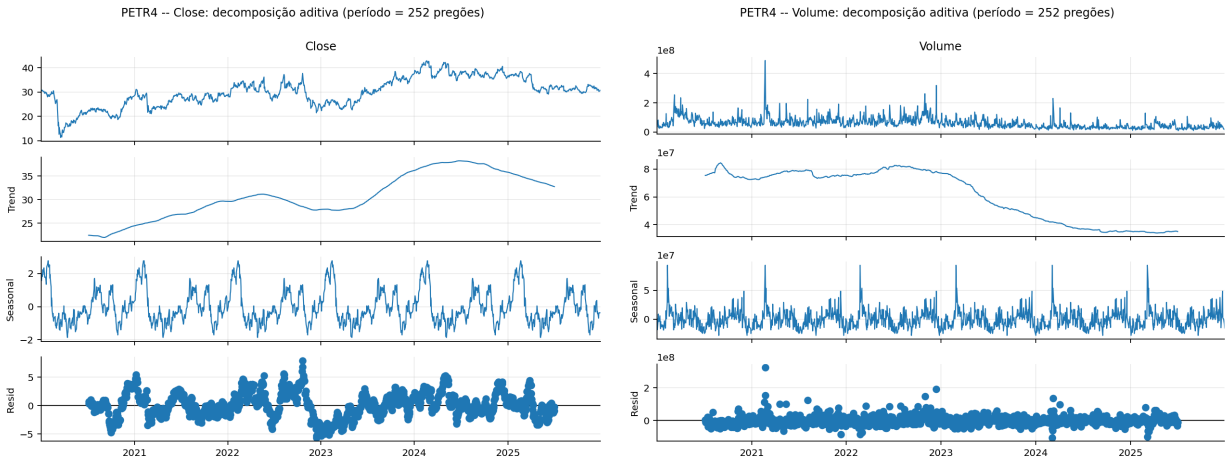


Figura 4: Decomposição aditiva (tendência, sazonalidade anual e resíduo) de *Close* e *Volume*.

Autocorrelação

Resposta

Close: autocorrelação **muito forte e persistente**: $\rho(1) = 0{,}993$, $\rho(5) = 0{,}963$, $\rho(21) = 0{,}849$, $\rho(63) = 0{,}669$, com decaimento lento e aproximadamente linear da ACF – assinatura típica de um passeio aleatório (raiz unitária). A PACF corta após o lag 1, o que indica que praticamente toda a dependência é explicada pelo valor do dia anterior. O passado "ajuda a responder o presente" apenas no sentido de que o preço de hoje é a melhor estimativa do de amanhã: a ACF da *primeira diferença* (retornos) é nula em todos os lags ($\rho(1) = 0{,}000$), ou seja, as variações diárias não são previsíveis linearmente a partir das variações passadas.
Volume: autocorrelação **moderada e de decaimento rápido**: $\rho(1) = 0{,}64$, $\rho(5) = 0{,}43$, $\rho(21) = 0{,}27$, estabilizando em torno de 0,15–0,25 para lags longos (efeito da tendência decrescente). Dias de volume alto tendem a ser seguidos por dias de volume alto (*agrupamento* de atividade), mas a memória é curta. A ACF da diferença é negativa no lag 1 ($-0{,}31$), sinal de reversão à média: um salto de volume tende a ser parcialmente desfeito no dia seguinte.

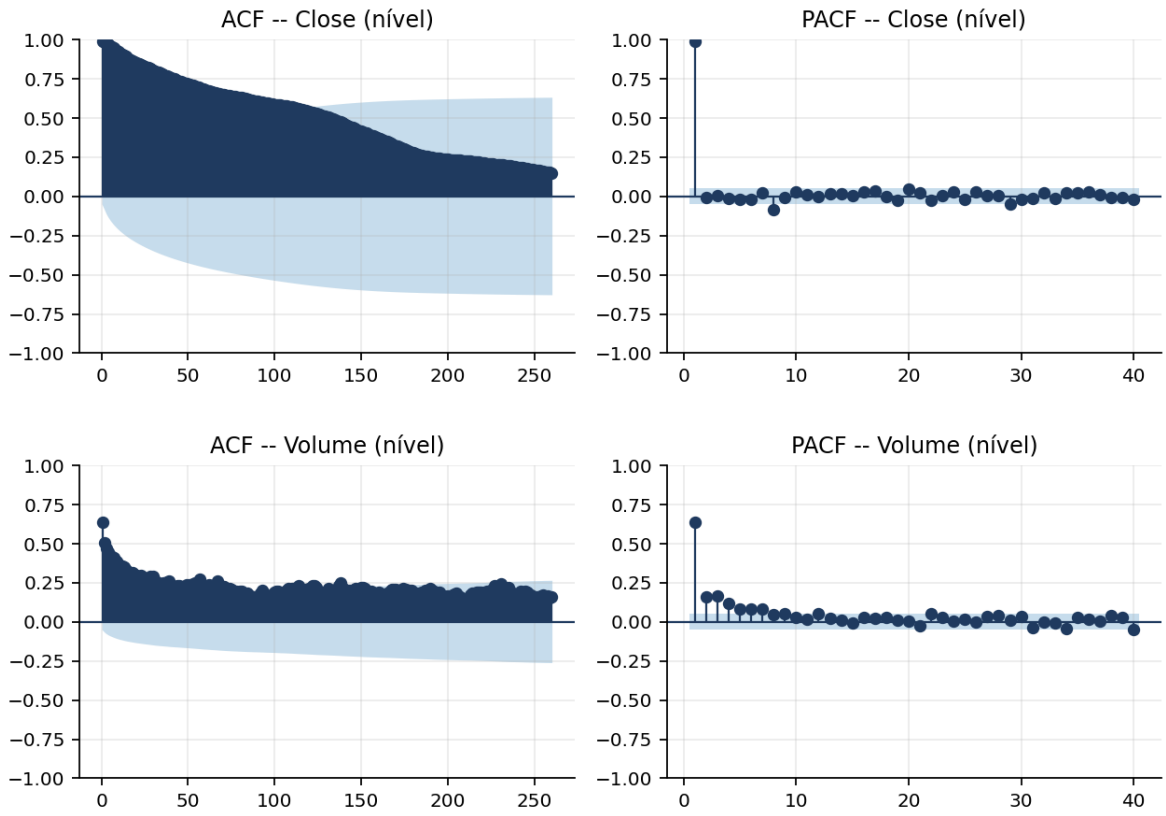


Figura 5: ACF (até 260 lags) e PACF (40 lags) das séries em nível; a faixa azul é o intervalo de confiança de 95%.

Estacionariedade

Resposta

Close: não estacionária. O teste ADF não rejeita a hipótese de raiz unitária ($p = 0{,}153$) e o KPSS rejeita a hipótese de estacionariedade ($p = 0{,}01$); os dois testes concordam. As estatísticas por janela confirmam: a média passa de 23,0 para 37,1 entre a 1ª e a 4ª janela e o desvio-padrão varia de 2,7 a 4,7. A *primeira diferença*, porém, é estacionária (ADF $p < 10^{-10}$; KPSS $p = 0{,}10$, não rejeita) – a série é integrada de ordem 1, $I(1)$, o que justifica o componente "I" com $d = 1$ de um modelo ARIMA, tema da Aula 2.

Volume: não estacionária, mas por razão diferente. O ADF rejeita a raiz unitária ($p \approx 10^{-5}$): não há passeio aleatório, a série oscila em torno de um nível. Entretanto o KPSS também rejeita a estacionariedade ($p = 0{,}01$), porque esse nível *muda* ao longo do tempo (tendência decrescente: médias por janela de 79,6 M para 34,9 M) e a variância também cai (desvio de 46,6 M para 17,2 M). Trata-se de *não estacionariedade em tendência e em variância*, tratável por diferenciação ou por transformação logarítmica seguida de remoção da tendência. A divergência entre ADF e KPSS é justamente o caso em que a série é "estacionária em torno de uma tendência", e ilustra por que os slides recomendam olhar as estatísticas em janelas além dos testes.

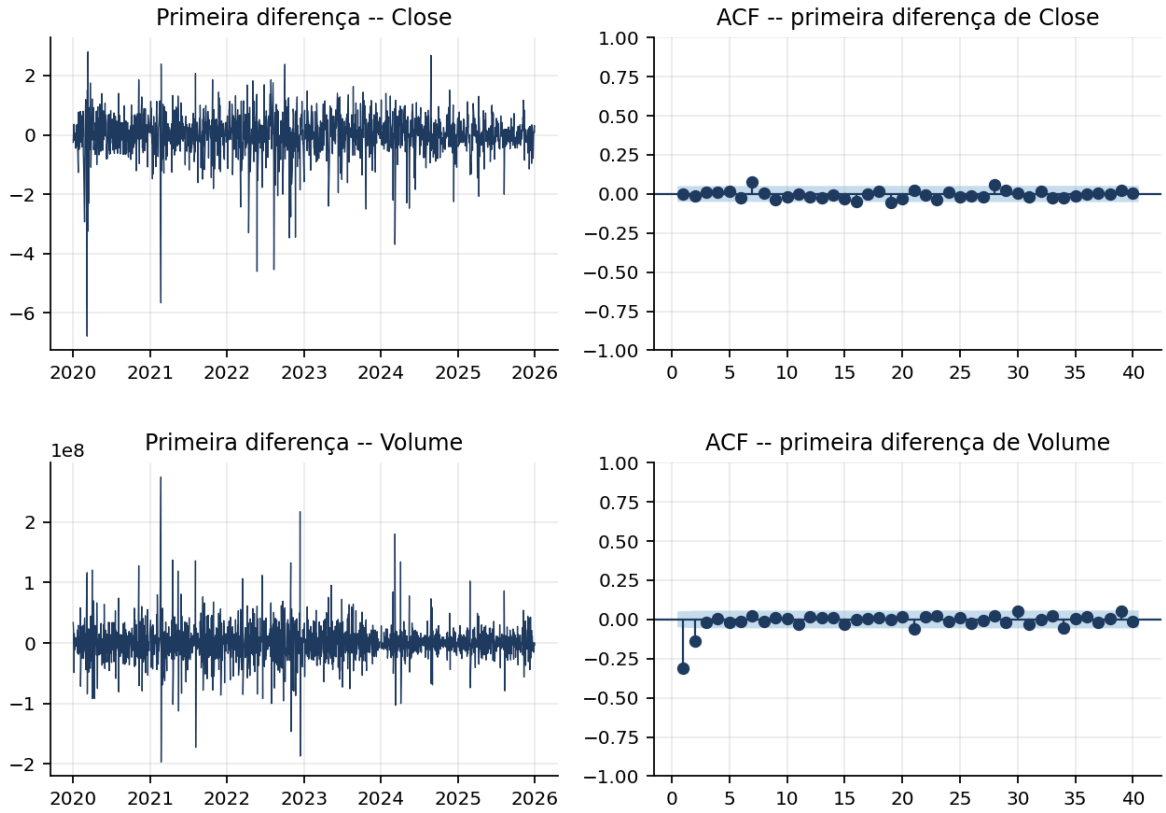


Figura 6: Primeira diferença das séries e sua ACF: os retornos de *Close* não têm autocorrelação; a diferença do *Volume* apresenta reversão à média (lag 1 negativo).

Síntese

A série PETR4 é multivariada (5 variáveis $\times$ 1494 pregões, uma observação por dia útil), com fechamento máximo de R$ 42,90 em 19/02/2024. O *Close* é um processo altamente autocorrelacionado, não estacionário (raiz unitária), com tendência local não monotônica, ciclos irregulares de origem econômica e sem sazonalidade; sua primeira diferença é ruído sem memória. O *Volume* tem tendência decrescente, memória curta, reversão à média, ciclos ligados a episódios de estresse do mercado e também não apresenta sazonalidade. Essas conclusões orientam a Aula 2: para o preço, baselines *naive* (último valor) e modelos com diferenciação (ARIMA com $d = 1$) são pontos de partida naturais; para o volume, modelos que capturem nível variável e memória curta.

Arquivos entregues: `analise_petr4.py` (script completo), `PETR4.csv`, `resultados.json` e a pasta `figuras/`.