Atividade da Aula 2 – Forecasting da série UNRATE com ETS e LSTM

César Willian Pacheco

Especialização em Inteligência Artificial & Ciência de Dados – PUCPR

Prof. Vinícius Mourão Alves de Souza

Setembro de 2026

Enunciado e dados

Dada a série UNRATE (taxa mensal de desemprego nos EUA desde 1948): fazer as previsões das últimas 12 observações com o modelo ETS e com o modelo LSTM e responder qual modelo apresentou o menor erro (RMSE).

A série foi obtida diretamente do FRED (`https://fred.stlouisfed.org/series/UNRATE`), a mesma fonte do arquivo `UNRATE.csv` do professor: 944 observações mensais de janeiro/1948 a agosto/2026, taxa *dessazonalizada* (*seasonally adjusted*) pelo BLS. A observação de outubro/2025 não foi publicada (paralisação do governo americano) e aparece como "." no arquivo; ela foi removida com `dropna()`, a mesma convenção do notebook do professor, restando 943 valores. Todos os resultados foram gerados pelo script `forecasting_unrate.py` (statsmodels 0.15, TensorFlow/Keras 2.21), anexo.

1 Protocolo experimental

- **Holdout temporal.** Teste = as **12 últimas observações** (agosto/2025 a agosto/2026, sem outubro/2025); treino = as 931 anteriores. Nada é embaralhado: a validação cruzada aleatória vazaria informação do futuro para o passado.
- **Métrica.** RMSE $= \sqrt{\frac{1}{12}\sum(y_i - \hat{y}_i)^2}$, em pontos percentuais de desemprego; MAE e MAPE são reportados como apoio.
- **Baselines.** Mean, naive (repete o último valor) e drift, como referência da dificuldade do problema.
- **Sem vazamento.** A escolha da configuração do ETS usa o AICc calculado *no treino*; a escolha da configuração da LSTM usa a perda de *validação* (últimos 20% das janelas de treino); o `MinMaxScaler` é ajustado só no treino. O conjunto de teste é usado uma única vez, ao final.



Figura 1: UNRATE (1948–2026). A linha tracejada marca o início das 12 observações de teste.

2 ETS: escolha da configuração e resultado

Resposta

Justificativa da configuração. A série tem *nível* que muda lentamente e *ciclos* de duração irregular (recessões e expansões, como mostrado na Aula 1), mas **não tem sazonalidade** – ela já é publicada dessazonalizada – e não tem uma tendência global (oscila entre 2,5% e 14,8% e termina próximo de onde começou). Logo, os candidatos naturais são os modelos *sem componente sazonal*: ETS(A,N,N) (só nível, equivalente à suavização exponencial simples), ETS(A,A,N) (Holt, com tendência aditiva) e ETS(A,Ad,N) (tendência amortecida). Versões com sazonalidade aditiva ($m = 12$) foram ajustadas apenas para confirmar que não ajudam. O erro é aditivo porque a amplitude das flutuações não cresce com o nível da série. A seleção entre candidatos foi feita pelo **AICc no treino** (Hyndman & Athanasopoulos, cap. 8), sem olhar o teste.

Modelo	Parâmetros	AICc (treino)	RMSE (teste)	MAE (teste)
ETS(A,N,N)	2	**1010,44**	**0,1155**	0,0833
ETS(A,A,N)	4	1014,57	0,1183	0,0872
ETS(A,Ad,N)	5	1015,58	0,1155	0,0834
ETS(A,N,A), $m = 12$	15	1027,29	0,1533	0,1368
ETS(A,A,A), $m = 12$	17	1031,53	0,1546	0,1372
ETS(A,Ad,A), $m = 12$	18	1032,69	0,1525	0,1358
Baseline mean	–	–	1,3768	1,3720
Baseline naive	–	–	0,1155	0,0833
Baseline drift	–	–	0,1183	0,0872

Resultado do ETS

O modelo selecionado é o **ETS(A,N,N)**, com $\alpha = 0{,}9999$ e nível inicial 3,40. Com $\alpha \approx 1$ a equação do nível $\ell_t = \alpha x_t + (1-\alpha)\ell_{t-1}$ reduz-se a $\ell_t = x_t$: a previsão para todo o horizonte é o

último valor observado, $\hat{y}_{t+h} = 4{,}3$ para $h = 1, \ldots, 12$. Ou seja, o melhor ETS **coincide com o baseline naive**, e a tabela mostra que tendência (Holt) e sazonalidade só pioram o AICc e o erro de teste. Isso não é uma falha do método: a taxa de desemprego mensal comporta-se como um passeio aleatório – mudanças pequenas e persistentes, sem padrão sazonal –, e para esse tipo de série a teoria diz que a melhor previsão pontual é o valor corrente. **RMSE do ETS = 0,1155** pontos percentuais (MAE 0,083; MAPE 1,95%).

3 LSTM: arquitetura, hiperparâmetros e resultado

Resposta

Arquitetura (deliberadamente pequena). Segue o notebook do professor: entrada com w passos e 1 variável → camada `LSTM(u)` → camada `Dense(12)` que emite os 12 valores de uma vez (abordagem *direta*, multi-output, que evita o acúmulo de erros da abordagem recursiva). Otimizador Adam, perda MSE, *batch* 8, até 300 épocas com *early stopping* (paciência 20, restaurando os melhores pesos) monitorando os últimos 20% das janelas de treino (`shuffle=False`, para que a validação seja o trecho mais recente). A série é escalada para $[0, 1]$ com `MinMaxScaler` ajustado só no treino.

Seleção da janela e das unidades. Testaram-se $(w, u) \in \{(12, 8), (24, 8), (24, 16), (36, 8)\}$, escolhendo pela perda de validação média de 3 sementes:

w	u	janelas de treino	parâmetros	perda de validação (MSE, escala [0,1])
12	**8**	908	428	**0,01522**
24	8	896	428	0,01566
24	16	896	1356	0,01550
36	8	884	428	0,01617

A configuração final tem **janela de 12 meses, 8 unidades LSTM e 428 parâmetros treináveis**; o treinamento parou entre 37 e 51 épocas. Como os pesos iniciais são aleatórios, o modelo foi treinado com 5 sementes (0 a 4).

Execução da LSTM ($w = 12$, $u = 8$)	**RMSE**	**MAE**	**épocas**
semente 0 (execução principal)	0,3720	0,3058	41
semente 1	0,3981	0,3003	51
semente 2	0,3768	0,2933	42
semente 3	0,3633	0,2700	37
semente 4	0,3452	0,2666	39
média ± desvio das 5 sementes	0,3711 ± 0,0173		
previsão média das 5 sementes (*ensemble*)	0,3643		

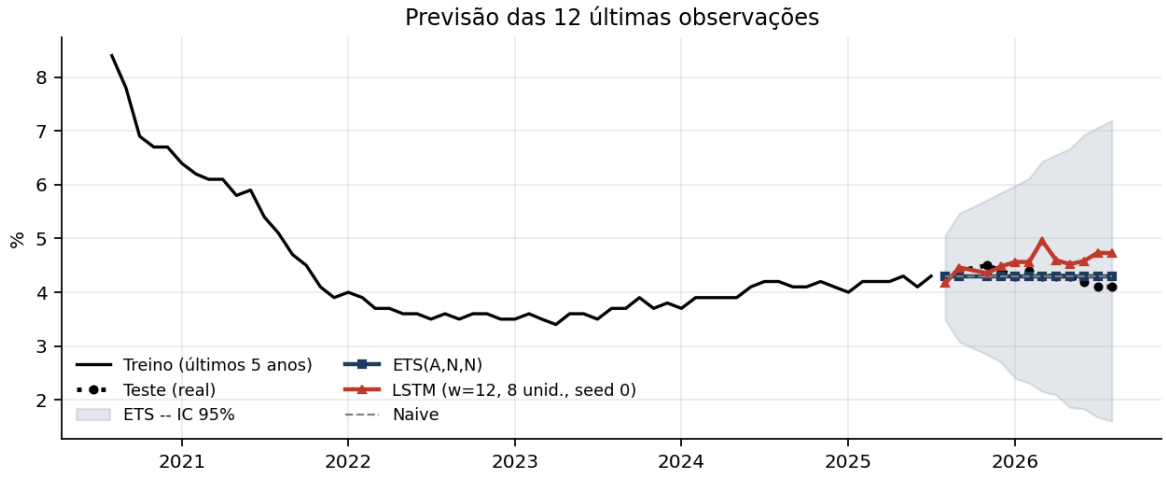


Figura 2: Últimos cinco anos de treino, valores reais de teste e previsões do ETS(A,N,N) (com intervalo de 95% simulado) e da LSTM.

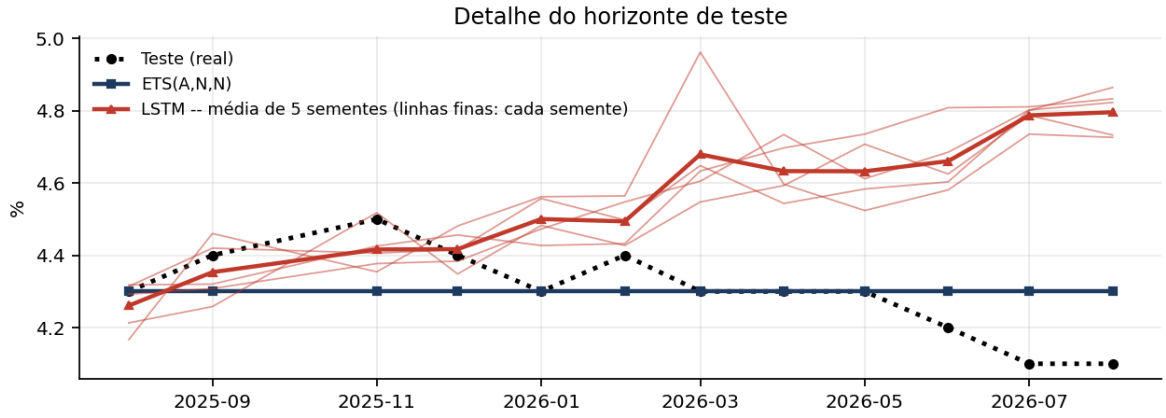


Figura 3: Detalhe do horizonte de teste: cada linha fina é uma semente da LSTM; a linha grossa é a média.

4 Qual modelo apresentou o menor RMSE – e por quê

Resposta

O ETS venceu com folga: RMSE = 0,116 contra 0,371 ± 0,017 da LSTM (3,2 vezes maior). Nenhuma das cinco sementes da LSTM (melhor caso 0,345) chegou perto do ETS, e nem a média das cinco previsões (0,364). A LSTM previu uma *alta* gradual do desemprego, de 4,3% para ≈ 4,8%, enquanto a série ficou estável e depois caiu para 4,1%; o ETS previu simplesmente 4,3% e errou, em média, 0,08 ponto.

Por que isso acontece (relacionando com o que foi visto em aula):

1. **Natureza da série.** A UNRATE é dessazonalizada, sem tendência global e com autocorrelação de lag 1 próxima de 1: um passeio aleatório com pequenas variações mensais (na Aula 1, o mesmo diagnóstico de não estacionariedade por raiz unitária). Para uma série assim, "a melhor previsão é o último valor" – e o ETS, ao estimar $\alpha \approx 1$, *descobriu isso a partir dos dados.* É o caso citado nos slides em que "modelos com pressupostos adequados

sobre a série podem ser mais eficazes" e em que baselines são competitivos com métodos complexos.

2. **Poucos dados para a LSTM.** Embora a série tenha 931 observações de treino, a rede aprende com ≈ 900 janelas altamente sobrepostas, quase todas em regimes (nível de 3% a 11%, recessões, o choque de 14,8% em abril/2020) diferentes do regime atual, estável em torno de 4%. A validação – os últimos 20% das janelas – inclui justamente a explosão de 2020, o que torna a perda de validação ruidosa e o *early stopping* pouco informativo (parou entre 37 e 51 épocas). Os slides registram exatamente este ponto: com poucos dados, arquiteturas de *deep learning* mais complexas não garantem melhor desempenho.

3. **Viés de reversão à média aprendido.** Na história da série, um nível baixo de desemprego costuma ser seguido de alta (fins de ciclo); a LSTM generalizou esse padrão e projetou uma subida que não ocorreu – um erro de *extrapolação de regime*, típico de modelos que aprendem dependências não lineares em séries curtas. O ETS, sem memória além do nível, não carrega esse viés.

4. **Variância entre execuções.** O RMSE da LSTM oscila entre 0,345 e 0,398 só por trocar a semente, uma faixa maior do que o próprio RMSE do ETS. Um modelo cuja resposta depende tanto da inicialização exige repetições e *ensembles* para ser comparado com honestidade; o ETS é determinístico e tem dois parâmetros.

5. **Escala e horizonte.** Ambos os modelos foram avaliados em previsão de longo prazo ($h = 12$) sem atualizar o histórico. Nesse cenário o ETS entrega, além da previsão pontual, um intervalo de 95% que cobre todos os valores observados (Figura 2), enquanto a LSTM, sem tratamento probabilístico, entrega apenas pontos – e pontos viesados.

Conclusão. ETS(A,N,N): RMSE 0,116 < LSTM: RMSE 0,371. O resultado ilustra o *No Free Lunch* da Aula 2: a LSTM não é "pior" em geral – em séries com padrões não lineares fortes e muitos dados ela pode vencer –, mas para uma série curta, dessazonalizada e próxima de um passeio aleatório, um modelo estatístico simples, cujos pressupostos coincidem com a dinâmica da série, é mais preciso, mais estável e mais interpretável.

Trecho essencial do código

```
# ETS -- candidatos sem sazonalidade escolhidos pelo AICc no treino
fit = ETSModel(train, error="add", trend=None, seasonal=None).fit(disp=False)
ets_pred = fit.forecast(12)                    # alpha estimado = 0,9999 -> previsão = último
    valor

# LSTM -- abordagem direta, janela 12 -> 12 saídas (arquitetura do notebook do professor)
scaler = MinMaxScaler().fit(train.reshape(-1, 1))        # ajustado só no treino
X, y = janelas_diretas(scaler.transform(train.reshape(-1, 1)).ravel(), w=12, hz=12)
model = Sequential([Input(shape=(12, 1)), LSTM(8), Dense(12)])
model.compile(optimizer="adam", loss="mse")
model.fit(X, y, epochs=300, batch_size=8, validation_split=0.2, shuffle=False,
          callbacks=[EarlyStopping(monitor="val_loss", patience=20, restore_best_weights=True)])
```

```
lstm_pred = scaler.inverse_transform(model.predict(tr[-12:].reshape(1, 12, 1)).reshape(-1, 1)).
    ravel()
```

Arquivos entregues: `forecasting_unrate.py`, `UNRATE.csv`, `resultados.json` (todas as métricas, parâmetros e previsões) e `figuras/`.